基于方言语音识别的智能家居语音转换装置

本科工程导论开题报告

陶理

October 30, 2026

1. 研究背景与问题
2. 前期研究基础
3. 项目目标
4. 系统方案与技术路线
5. 数据采集与实验设计
6. 硬件与进度
7. 风险与预期成果
8. 参考文献

研究背景

- 很多老年人习惯使用方言，而主流智能家居设备主要面向普通话。
- 方言口音会导致语音识别率下降，影响老人使用智能家居。
- 现有智能音箱多为封闭系统，普通开发者难以修改固件或接入厂商接口。

问题提出

- 已有研究多关注普通话语音识别，方言识别资源较少。
- 前期研究已经完成方言指令识别模型、置信度拒识与串口控制链路。
- 本项目要把离线研究转化为一个可外接、可实时运行、可现场展示的装置。
- 工程化过程中发现并修正了一个关键问题：训练输入与线上输入分布不一致。

前期研究基础

- 粤语家居指令语料库与合成语料生成流水线（2904 条）。
- log-mel 与 MFCC 特征提取，整句 CMVN 归一化。
- 多条识别路线：DTW 模板匹配、回归映射、Softmax 回归、线性 SVM、1D-CNN。
- 温度标定置信度与阈值拒识。
- 串口协议、模拟设备与 Web 演示台。

特征提取

Mel 刻度：

$$Mel(f) = 2595 \log_{10}(1 + f/700) \tag{1}$$

加窗：

$$w(n) = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right) \tag{2}$$

短时傅里叶变换：

$$X(m, \omega) = \sum_{n=-\infty}^{\infty} x(n) w(n-m) e^{-j\omega n} \tag{3}$$

整句 CMVN 消除信道与音量差异。

一条被否决的技术路线

前期曾以「方言特征 $\rightarrow$ 普通话特征」的回归映射为主线：

$$\hat{y} = \beta_0 + \beta_1 x \tag{4}$$

- 特征级指标很好：RMSE 0.025，余弦相似度 0.999。
- 但映射后命令识别准确率 0.1667，与 6 类随机基线相同。
- 原因：统一回归矩阵未按命令类别条件化，类别判别边界被抹平。
- 结论：转换必须发生在语义层，不能发生在特征层。

本项目的核心工程发现

- 模型原本在带尾部静音的整段音频上训练，线上 VAD 输出却紧贴语音。
- 整句 CMVN 下，尾部静音稀释了均值与方差，输入分布一变模型失效。
- 短命令受损最重：LIGHT_ON 准确率由 0.9893 掉到 0.1716。
- 处置：用部署同款 VAD 重生成训练语料，再重新训练。
- 原则：训练输入与部署输入必须同源。

修复后的实测结果

- 部署模型：在部署同款 VAD 裁剪后的同源语料上重训练；拒识阈值 0.945。
- 测试集 483 条未见表达组：argmax 准确率 0.8799，接受样本准确率 0.9319。
- 未知指令误接受率 0.125，修复前为 0.4444。
- 单条推理延迟 13–16 ms，纯 numpy 推理，不联网。
- 如实说明：验证集 0.9477 与测试集 0.8799 相差 6.8 点，弱项集中在窗帘类命令，需优先补采这两类的真人表达。

项目目标

- 做一个智能家居语音转换装置。
- 用户说方言，装置在端侧完成识别与置信度判断。
- 通过扬声器播放标准普通话指令，驱动智能音箱执行。
- 支持 6 条固定家居命令。
- 通过 OLED 显示识别结果与置信度。
- 保留 ESP32-S3 串口与继电器直控作为演示备用。

系统总体方案

- 输入：麦克风采集方言语音。
- 计算：端侧完成 VAD、特征提取、分类与拒识。
- 输出：扬声器播放标准普通话指令，OLED 显示结果。
- 执行：智能音箱接收普通话指令并控制家居设备。
- 备用：串口 ESP32-S3 或继电器直接控制演示设备。

技术路线

总体流程：

方言语音 → VAD → log-mel40+Δ → CNN 集成 → 置信度 → 拒识 → 普通话指令 → 智能音箱执行

- 特征：40 维 log-mel 及一阶差分，整句 CMVN，插值到 256 帧。
- 模型：1D-CNN 三种子集成，纯 numpy 推理，约 1.35 MB。
- 拒识：温度标定最大概率，阈值只在验证集与未知校准集上选取。
- 语义层映射：命令标签 → 普通话指令 → 预录音频播放。

VAD 端点检测

- 帧能量转 dB，自适应噪声底（最小值统计）。
- 判决门限：噪声底 + 门限余量。
- 静音挂起判定语音结束，保留前置上下文避免吃掉起始音。
- 输出前后裁剪过的语音段，作为模型输入。
- 与训练语料生成使用同一实现，保证训练与部署同源。

智能音箱外接联动

- 不修改智能音箱固件，不依赖厂商 API。
- 装置播放预录的普通话命令音频。
- 智能音箱识别后执行家居控制。
- 若现场联动不稳定，改用 ESP32-S3 串口或继电器直接控制演示设备。

命令词与数据采集

- 命令词：开灯、关灯、开窗帘、关窗帘、全部关闭、查询状态。
- 合成语料：2904 条，3 个粤语音色，含语速/音高条件与纠正否定句式。
- 真人语料：2–3 位方言使用者，每人每命令 30–50 次。
- 未知指令负样本：用于标定拒识阈值。
- 环境：安静环境加电视/风扇背景噪声。
- 划分：按表达组划分固定训练/验证/测试集，避免泄漏。

实验与评价指标

- 对比方法：MFCC+DTW 基线与 log-mel+CNN。
- 消融：VAD 前 / 后，验证端点检测对准确率与误接受率的影响。
- 测试条件：安静/噪声、近/远距离、已注册/未注册用户。
- 指标：识别准确率、接受样本准确率、未知指令误接受率、端到端延迟、执行成功率、误触发率、总成本。

硬件与预算

部件	估价（元）
树莓派 4B/Zero 2W	0–400
USB 麦克风	50–150
扬声器与功放	30–80
ESP32-S3 开发板	60–90
SG90 舵机 / LED / 按键	20–40
OLED	15–25
电源、线材、外壳	130–250

- 合计约 305–1085 元，按 1000 元以内控制；价格为估算，未实时核价。

进度安排

- 第 1 周：需求确认、技术路线修订、硬件清单与采购。
- 第 2 周：VAD、实时管线、普通话播报、双备用执行层打通。
- 第 3 周：真人数据采集、训练语料同源重生成与重训练。
- 第 4 周：拒识阈值标定与安全评估。
- 第 5 周：多人、噪声、距离测试与端到端延迟实测。
- 第 6 周：硬件联调与现场演示彩排。
- 第 7 周：成本核算、演示视频、答辩 PPT。
- 第 8 周：答辩与材料归档。

风险与应对

- 合成与真人存在域差距：补真人语料，报告区分合成与实测数字。
- 未知指令误接受（最突出短板）：补采负样本、阈值仅在校准集选取、演示展示低置信度拒识。
- 智能音箱识别不稳定：预录普通话音频，准备串口与继电器两条备用通道。
- 真人语料不足：固定 6 条命令，2–3 位使用者反复采集，必要时用个性化注册模板补充。
- 端侧实时性不足：优先树莓派 4B，模型已纯 numpy 推理且体积 1.35 MB。
- 现场演示失败：准备预录视频、备用音频与继电器演示。

预期成果

- 方言语音智能家居控制原型。
- 方言与普通话指令数据及标注（合成与真人分开标注来源）。
- 端侧推理程序与自包含运行时（纯 numpy，可离线运行）。
- 智能音箱联动演示与双备用通道演示。
- 测试报告、成本表、3 分钟演示视频与答辩 PPT。
- 技术路线修订说明：记录被否决方案及其实验依据。

参考文献

- 申请人前期研究：方言家居指令识别与控制，实验记录与代码仓库。
- Davis S, Mermelstein P. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1980.
- MFCC、log-mel 特征、DTW、CNN 语音命令识别与智能家居语音交互相关文献。